

Павел Донин

AI Engineer — оркестрация агентов, инструменты для LLM

Агентные харнессы, оркестрация и MCP-инструменты в проде — для команды студии и пользователей у клиентов · 12 лет в разработке, 5 из них — тимлид и руководитель разработки

Контакты

doninpr@gmail.com · linkedin.com/in/doninpr · t.me/doninpr · github.com/prineycom

Нови-Сад, Сербия (CET, UTC+1) · удалённо, часовой пояс EC · рассматриваю full-time позиции AI Engineer, Agent Platform, Applied AI и Forward Deployed по всему миру · B2B-контракт или EOR

О себе

AI-инженер: проектирую агентные системы — MCP-серверы, сабагенты, скиллы — и отвечаю за их стабильную работу в проде. Перевёл команду из 7 человек на разработку через агентов и автоматизировал её бизнес-процессы: LLM-агенты на Hermes Agent со скиллами, интеграции с Microsoft 365 через MCP и мои собственные evals — поверх корпоративной БД. Для клиентов спроектировал модель изоляции платформы хостинга агентов и сопровождаю RAG-ассистента по медицинским данным; в соавторстве собрал плагин оркестратора для Claude Code, через который идёт моя разработка. Интересуюсь инференсом маленьких открытых моделей и экспериментирую с ними на своем железе: провожу бенчмарки, оптимизирую параметры инференса под ограниченные ресурсы, оптимизирую агентов для работы с локальными моделями, экспериментирую с fine-tuning маленьких моделей. 12 лет full-stack-разработки (Python, TypeScript), 5 из них — тимлид и руководитель разработки.

AI-проекты

Пайплайн разработки на LLM для продакшн-студии (Talking Birds & Flying Fish, авг. 2025 — н. в.)

- Перевёл команду студии на разработку через агентов: первый конфиг для агентов добавил в августе 2025, через год он стоял в 22 из 33 репозиториях, и все проекты 2026 года стартовали уже с него. Совместно с командой разработал и ввел воркфлоу «план → изолированный worktree → независимое ревью агентом → приёмка человеком → ship», который прижился в процессах команды; на той же кодовой базе музейной экспозиции мой объём кода за день вырос примерно втрое (2024 → 2026).
- Провёл работу студии через оркестратор yokemate: 80+ планов, написанных агентами, в 11 проектах студии — от музейных инсталляций до внутренних систем.

LLM-агенты для автоматизации бизнес-процессов (Talking Birds & Flying Fish, апр. 2026 — н. в.)

- Развернул агентов для сотрудников на Hermes Agent (open-source рантайм агентов от Nous Research) с общим банком скиллов, который написал сам: сметы на CG от брифа до просчитанной таблицы и PDF для клиента, помощь по шаблонам смет, внутренняя БД с защитой приватных данных в групповых чатах, поиск по базе регламентов. Агенты подключены к Microsoft 365 через MCP и покрыты набором evals на promptfoo, который проверяет срабатывание скиллов, выбор инструмента и флаги — с LLM-as-judge и лимитом расходов на прогон.
- Построил под них слой данных. Корпоративную БД спроектировал по итогам обследования всех отделов и их операционных таблиц; её схему из 22 миграций агент под моим управлением развернул через MCP-сервера по пошаговой промпт-спецификации с самопроверкой. Пайплайн данных на Python (Postgres → Microsoft Graph → SharePoint) в проде с сентября 2026; трекер отпусков для HR перевёл на эту базу за две недели (10 влитых PR, тестов с 21 до 135).
- Сконфигурировал Hermes агента для Microsoft Teams: HR-бот для всей компании (отпуска, ворклоги, календарь, поиск по регламентам) и агенты для руководства (retrieval-слой по документам SharePoint — на этапе интеграции).

Aleen — AI-ассистент по медицинским данным (клиент YokeLoop, июнь 2026 — н. в.)

- Держу в проде ассистента на Hermes Agent поверх RAG-системы на MCP по медицинским записям семьи, с изоляцией данных по tenants; 6 активных пользователей. Работаю с заказчиком напрямую: администрирую развёртывание на его сервере и настраиваю харнесс и агентов по его запросам.

yokemate — мультирепо-оркестратор по тикетам на Claude Code (YokeLoop, в соавторстве с [Иваном Хилковым](#), авг. 2026 — н. в.; код закрыт, демо по запросу)

- Веду через него разработку в 4 организациях и примерно 18 репозиториях — от тикета в трекере (YouTrack, GitHub Issues) до влитого PR: за первый месяц — 88 тикетов, 72 влиты с медианой 16 часов от плана до merge, каждый пятый с приёмки ушёл на доработку.
- Мультиагентный пайплайн: read-only сабагенты для разведки и планирования, реализация в изолированном worktree, независимый сабагент-ревьюер и merge только через человека; PreToolUse guard запрещает необратимые команды и называет разрешённую альтернативу, поэтому сессии задач идут без присмотра; модель выбирается под проект. Вырос из плагина [yoke](#), написанного в соавторстве; моя пересборка на open-source рантайме [pi](#), [yokemate-pi](#), показала, что workflow-first — неверный фундамент, и привела к memory-first-посреднику — [mypi](#), сейчас в разработке.

Голосовой агент реального времени — 3 итерации (личный R&D, апр. 2026 — н. в.) · [v1](#) · [v2](#) · [v3](#)

- Собрал speech-to-speech агента реального времени от и до — транспорт WebRTC, потоковый STT → LLM → TTS с barge-in и 3D-аватар, мимика которого следует за эмоцией голоса, — и уместил весь стек на одну видеокарту с 12 ГБ: срезал память NVIDIA Audio2Face-3D с 8,8 ГБ до ~0,4 ГБ, пересобрав его TensorRT-движок, а анимацию лица ускорил с ~3 с до 81 мс на фразу резидентным C++-хелпером для инференса.
- Дал ему инструменты: агент превращает речь в вызовы инструментов с валидацией по схеме, выполняет их в закрытой Docker-песочнице и отчитывается в Telegram; v3 идёт дальше — делегирует задачи кодировщикам-агентам. Каждую модель — STT, LLM, TTS — пропускал через пороги по латентности, real-time factor и VRAM, которые задал сам; решения зафиксированы в 37 ADR. Третья версия — осознанный rewrite: вторую признал переусложнённой.

Local-first лаборатория агентов (личный проект, февр. 2026 — н. в.)

- Держу Priney — своего персонального ассистента на Hermes Agent: он постоянно работает на моём Raspberry Pi 5 и закрывает задачи, календарь, почту, финансы, здоровье, знания и путешествия. Спроектировал его Second Brain — vault в Obsidian на 226 заметок, синхронизированный через CouchDB и git, с правилами, откуда агент читает и куда пишет, — и локальный RAG по нему (ONNX-эмбединги, векторы в SQLite, инкрементальная переиндексация); написал его MCP-интеграции и cron-автоматизации (монитор вотчлиста с приоритетами и тихими часами, дайджесты, бэкапы).
- Развернул у себя Qwen3.6-35B-A3B основной моделью своих агентов на одной видеокарте с 12 ГБ (offload MoE-экспертов, квантованный KV-кэш, контекст 262K) и добился от агента стабильной работы на ней: разобрался, почему он молча переставал вызывать инструменты — сжатие контекста схлопывало пары tool_call / tool_result, — и починил принудительным tool use и сжатием, которое бережёт историю вызовов; нашёл баг в апстриме: локальный прокси LiteLLM принимался за локальную модель, и таймаут стрима растягивался до 30 минут. Прогнал варианты LFM, Gemma и Qwen на видеокарте и на Pi.
- Написал `sp-cli` — open-source CLI на Python и MCP-сервер для приложения Super Productivity: 97 команд, MCP-инструменты генерируются из самого CLI, 919 тестов, CI на Python 3.11–3.13; за 2 дня его собрала автономная сессия агента на воркфлоу yoke.

Опыт работы

YokeLoop — сооснователь (интеграция агентов и внедрение у клиентов) — апр. 2026 — н. в.

Компания из двух основателей: продукты на LLM-агентах для малого и среднего бизнеса; я проектирую слой агентов и внедряю у клиентов, второй основатель строит платформу хостинга

- Спроектировал модель изоляции по принципу минимальных привилегий для нашей платформы хостинга агентов — Docker-песочница на каждого пользователя без Docker-сокета, секреты остаются на хосте, данные по тенантам — и написал гайд по контейнеру на сотрудника; разворачиваю и сопровождаю платформу у клиентов.
- Строю слой агентов для клиентов — банки скиллов, MCP-интеграции, evals на promptfoo; в соавторстве написал плагин yoke для Claude Code и оркестратор yokemate.

Talking Birds & Flying Fish — Tech Lead → Team Lead → Head of Development — июль 2024 — н. в.

Продакшн-студия в Барселоне: интерактивные инсталляции для корпоративных стендов на конференциях и музейных экспозиций; среди клиентов — Microsoft. Tech Lead (июль 2024), Team Lead (май 2025), Head of Development (январь 2026)

- Построил отдел разработки с нуля: начинал единственным веб-разработчиком, вырастил команду до 5 веб-разработчиков и 2 на Unreal Engine, определил стек и внутренние пакеты и выстроил весь процесс от задачи до релиза — планирование и декомпозиция в YouTrack, итерации под фиксированные даты выставок, код-ревью и CI/CD (GitHub Actions), управление релизами, надёжность (e2e- и soak-тесты для инсталляций, которые неделями работают без присмотра), observability (Sentry, Loki, Grafana) и культура documentation-first.
- Выпустил с командой 40 инсталляций (25 для посетителей) из 33 репозитория — стенды Microsoft, объехавшие конференции в 12 городах, игровые станции, постоянная музейная экспозиция; это 2 299 задач в трекере и 670 PR, и при этом сам писал код (1 128 своих коммитов). Общий @tb-ff/web-toolkit, который разрабатывал вместе с коллегами, используется в 18 из 33 проектов.

Sminex — Tech Lead, автоматизация бизнес-процессов — май 2022 — июль 2024

- Руководил командой из 3 человек у застройщика — выпустили 5 веб-сервисов для автоматизации строительных и эксплуатационных процессов с интеграцией во внутренние системы (TypeScript, NestJS, PostgreSQL, Django).

СУ-10 — Tech Lead, автоматизация строительных процессов — авг. 2021 — май 2022

- Руководил командой из 3 человек — от настройки процессов до MVP на Autodesk Forge (BIM) API; 1-е место на Autodesk Forge Hackathon 2021.

Ранее: RoadAR — визуализация облаков точек и данных SLAM (2022, парт-тайм); DataMap Geodata Laboratory — веб-сервисы ГИС (React, Node.js, AWS, Docker), 5+ проектов для клиентов, обучил 20+ студентов (2018 — 2021); фронтенд и веб-разработка (2014 — 2018).

Навыки и образование

- **Агенты и оркестрация:** Claude Code (скиллы, сабагенты, хуки), Claude Agent SDK (Anthropic API), Hermes Agent, pi, MCP-серверы, агентные и мультиагентные воркфлоу (orchestrator-worker, циклы ревью, human-in-the-loop gates), prompt и context engineering, structured outputs, tool / function calling, роутинг моделей
- **Evals, guardrails и observability:** promptfoo с LLM-as-judge, тестовые стенды, PreToolUse guards, песочницы на пользователя, минимальные привилегии, трейсинг в LangSmith, Sentry, Loki, Grafana
- **RAG и инференс:** retrieval (чанкинг, мультиязычные ONNX-эмбединги, векторные базы, SharePoint через Microsoft Graph), llama.cpp (квантизация, MoE offload, спекулятивный декодинг), TensorRT, Whisper и TTS-модели, ComfyUI
- **Провайдеры моделей и стек:** Anthropic, Ollama Cloud, OpenAI-совместимые API через LiteLLM, self-hosted open-weight Qwen / LFM / Gemma; Python (FastAPI, pytest), TypeScript, React, Electron, PostgreSQL, Supabase, SQLite, Docker, CI/CD на GitHub Actions, Dokploy, Tailscale; рабочая машина: Arch Linux (Omarchy), Neovim, herdr
- **Образование и языки:** «Информационные системы и технологии», МИИГАиК, Москва (2013 — 2017); русский (родной), английский (свободно), сербский (базовый)