

Павел Донин

AI Engineer — оркестрация агентов, LLM-инструменты

Agent harness'ы, оркестрация и MCP-инструменты в проде для команды студии и клиентских пользователей · 12 лет в разработке, 5 из них — тимлид и руководитель разработки

Контакты

doninpr@gmail.com · [linkedin.com/in/doninpr](https://www.linkedin.com/in/doninpr) · t.me/doninpr · github.com/prineycom

Нови-Сад, Сербия (CET, UTC+1) · удалённо, европейский часовой пояс · открыт к full-time полям AI Engineer, Agent Platform, Applied AI и Forward Deployed по всему миру · B2B-контракт или EOR

Кратко

AI-инженер: проектирую агентные системы — MCP-серверы, сабагенты, скиллы агентов — и надёжно веду их в проде. Перевёл команду студии из 7 человек на разработку с агентами и построил автоматизацию её бизнес-процессов: LLM-агенты на open-source рантайме Hermes Agent со скиллами, интеграциями с Microsoft 365 через MCP и evals, которые написал сам, поверх корпоративной базы, развёрнутой агентом по моей спецификации. Для клиентов спроектировал изоляцию платформы хостинга агентов и веду медицинского RAG-ассистента; соавтор оркестратора на Claude Code, через который идёт моя разработка. 12 лет full-stack разработки (Python, TypeScript), 5 из них — тимлид и руководитель разработки.

AI-проекты

LLM-пайплайн разработки для продакшн-студии (Talking Birds & Flying Fish, авг 2025 — н.в.)

- Перевёл команду студии на разработку с агентами: первую агентную конфигурацию добавил в августе 2025, через год она была в 22 из 33 репозиториях, а все проекты 2026 года стартовали с ней. Ввёл workflow «план → изолированный worktree → независимое агентное ревью → приёмка человеком → ship», который команда приняла, и измерил эффект атласом по истории git, трекера и PR.
- Вёл работу студии через оркестратор yokemate: 80+ планов, написанных агентами, по 11 проектам студии — от музейных инсталляций до внутренних систем.

LLM-агенты для автоматизации бизнес-процессов (Talking Birds & Flying Fish, апр 2026 — н.в.)

- Развернул агентов для сотрудников на Hermes Agent (open-source рантайм агентов от Nous Research) с общим банком скиллов, который написал сам: сметы на CG от брифа до просчитанной таблицы и PDF для клиента, экспертиза по шаблонам смет, внутренняя база данных с guardrails приватности для групповых чатов. Подключил Microsoft 365 через MCP и покрыл скиллы evals на promptfoo: срабатывание скилла, выбор инструмента и флаги, рубрика LLM-as-judge, лимит расходов на прогон.
- Построил слой данных для агентов: корпоративную базу, спроектированную по итогам обследования таблиц всех отделов; схему из 22 миграций развернул агент через Supabase MCP по пошаговой самопроверяющейся спецификации-промπτ. Ежечасный data pipeline на Python (Postgres → Microsoft Graph → SharePoint) в проде с сентября 2026; учёт отпусков HR перевёл на базу за две недели (10 смёрженных PR, тестов стало 135 вместо 21).
- Сделал боты в Microsoft Teams поверх базы: общекорпоративный HR-бот (отпуска и отгулы, ворклоги, календарь, поиск по регламентам) и боты для руководства для работы с данными (retrieval-слой по документам SharePoint — на этапе интеграции).

Aleen — AI-ассистент по медицинским данным (клиент YokeLoop, июн 2026 — н.в.)

- Эксплуатирую в проде ассистента на Hermes Agent поверх retrieval (RAG) системы на MCP по семейным медицинским записям, с изоляцией данных на клиента; 6 активных пользователей. Работаю напрямую с клиентом: администрирую сервер и настраиваю harness и агентов по его запросам.

yokemate — оркестратор разработки по тикетам для нескольких репозиторий на Claude Code (YokeLoop, в соавторстве с [Иваном Хилковым](#), авг 2026 — н.в.; закрытый, демо по запросу)

- Через него идёт моя разработка в 4 организациях и примерно 18 репозиториях — от тикетов в трекере (YouTrack, GitHub Issues) до смёрженных PR: за первый месяц провёл через него 88 тикетов, 72 смёржены с медианой 16 часов от плана до merge, каждый пятый возвращён на доработку на приёмке.
- Мультиагентный пайплайн: сабагенты-разведчик и планировщик только на чтение, реализация в изолированном worktree, независимый сабагент-ревьюер и merge только после решения человека; PreToolUse guard запрещает необратимые команды и называет разрешённую альтернативу, поэтому сессии задач идут без присмотра; модель выбирается под проект. Вырос из плагина [yoke](#) (соавторство); моя пересборка на рантайме [pi](#), [yokemate-pi](#), показала, что workflow-first — неверный фундамент, и привела к преемнику вокруг памяти.

Realtime голосовой агент — 3 итерации (личный R&D, апр 2026 — н.в.) · [v1](#) · [v2](#) · [v3](#)

- Собрал speech-to-speech агента реального времени целиком — транспорт WebRTC, потоковый STT → LLM → TTS с возможностью перебить агента и 3D-аватар, чьё лицо следует эмоциям голоса, — и уместил весь стек на одну видеокарту 12 ГБ: снизил память NVIDIA Audio2Face-3D с 8,8 ГБ до ~0,4 ГБ, пересобрав его TensorRT-движок, и время анимации лица с ~3 с до 81 мс на фразу через постоянный C++-хелпер инференса.
- Дал ему руки: агент превращает речь в вызовы инструментов, проверенные по схеме, выполняет их в закрытой Docker-песочнице и отправляет результаты в Telegram; v3 расширяет это до делегирования задач coding-агентам. Каждый выбор модели — STT, LLM, TTS — проходил заданные мной пороги по задержке, real-time factor и VRAM и зафиксирован в 37 ADR; третью версию осознанно переписал, признав вторую переусложнённой.

Local-first лаборатория агентов (личный проект, фев 2026 — н.в.)

- Веду Priney — своего постоянно работающего персонального ассистента на Hermes Agent, развёрнутого на Raspberry Pi 5: задачи, календарь, почта, финансы, здоровье, знания и путешествия. Спроектировал его Second Brain — Obsidian-хранилище из 226 заметок с правилами, где агенту читать и куда писать, синхронизация через CouchDB и git — с локальным RAG по нему (ONNX-эмбединги, векторы в SQLite, инкрементальная переиндексация); написал его MCP-интеграции и cron-автоматизации (монитор с приоритетами и тихими часами, сводки, бэкапы).
- Развернул Qwen3.6-35B-A3B основной моделью своих агентов на одной видеокарте 12 ГБ (выгрузка MoE-экспертов на CPU, квантованный KV-кэш, контекст 262K) и добился надёжной работы агента на ней: нашёл причину молчаливого отказа от вызова инструментов — сжатие контекста схлопывало пары tool_call / tool_result — и исправил её принудительным вызовом инструментов и сжатием, сохраняющим историю вызовов; нашёл баг в апстриме, из-за которого локальный прокси LiteLLM принимался за локальную модель и таймаут стрима растягивался до 30 минут; тестировал LFM, Gemma и Qwen на видеокарте и на Pi.
- Написал [sp-cli](#) — open-source CLI на Python и MCP-сервер для приложения Super Productivity: 97 команд, MCP-инструменты генерируются из самого CLI, 919 тестов, CI на Python 3.11–3.13; собран за 2 дня автономной агентной сессией по workflow yoke.

Опыт работы

YokeLoop — сооснователь (интеграция агентов и работа с клиентами) — апр 2026 — н.в.

Компания двух основателей: продукты на LLM-агентах для малого и среднего бизнеса; я проектирую агентный слой и веду клиентские внедрения, сооснователь строит платформу хостинга

- Спроектировал модель изоляции с минимальными привилегиями для нашей платформы хостинга агентов — Docker-песочница на пользователя без Docker-сокета, ключи остаются на хосте, данные разделены по клиентам — и написал гайд по контейнеру на сотрудника; разворачиваю и эксплуатирую платформу у клиентов.
- Строю агентный слой для клиентов — банки скиллов, MCP-интеграции, evals на promptfoo; соавтор плагина yoke для Claude Code и оркестратора yokemate.

Talking Birds & Flying Fish — Tech Lead → Team Lead → Head of Development — июл 2024 — н.в.

Продакшн-студия из Барселоны: интерактивные инсталляции для корпоративных стендов на конференциях и музейных экспозиций; среди клиентов — Microsoft. Tech Lead (июл 2024), Team Lead (май 2025), Head of Development (янв 2026)

- Построил отдел разработки с нуля: начинал единственным веб-разработчиком и вырастил отдел до 5 веб- и 2 Unreal Engine-разработчиков, определил стек и внутренние пакеты, выстроил весь процесс поставки — планирование и декомпозиция в YouTrack, итеративный цикл под фиксированные даты выставок, code review и CI/CD (GitHub Actions), управление релизами, reliability engineering с e2e- и soak-тестами для инсталляций, которые неделями работают без присмотра, observability (Sentry, Loki, Grafana) и культура документации.
- Выпустили 40 инсталляций (25 для посетителей) из 33 репозиторийев — стенды Microsoft на конференциях в 12 городах, игровые станции, постоянная музейная экспозиция — 2 299 задач в треке и 670 PR; при этом сам писал код (1 128 своих коммитов); общая библиотека @tb-ff/web-toolkit, которую разрабатывал вместе с командой, используется в 18 из 33 проектов.
- Разработчиком на музейной экспозиции заменил устаревший распознаватель детских рисунков на .NET сервисом на Python и OpenCV, не трогая установленное оборудование; построил тестовый стенд на 40 кейсов, диагностикой опроверг собственный план исправления и перенёс оставшийся класс ошибок в маркерные коды на печатном бланке.

Sminex — Tech Lead, автоматизация бизнес-процессов — май 2022 — июл 2024

- Руководил командой из 3 человек в девелоперской компании; выпустили 5 веб-сервисов, автоматизирующих строительные и операционные процессы, с интеграцией во внутренние системы (TypeScript, NestJS, PostgreSQL, Django).

СУ-10 — Tech Lead, автоматизация строительных процессов — авг 2021 — май 2022

- Руководил командой из 3 человек от настройки процессов до MVP на Autodesk Forge (BIM) API; 1-е место на Autodesk Forge Hackathon 2021.

Ранее: RoadAR — визуализация облаков точек и данных SLAM (2022, частичная занятость); DataMap Geodata Laboratory — веб-сервисы ГИС (React, Node.js, AWS, Docker), 5+ клиентских проектов, обучил 20+ студентов (2018 — 2021); фронтенд и веб-разработка (2014 — 2018).

Навыки и образование

- **Агенты и оркестрация:** Claude Code (скиллы, сабагенты, хуки), Claude Agent SDK (Anthropic API), Hermes Agent, pi, MCP-серверы, агентные и мультиагентные workflow (orchestrator-worker, циклы ревью, human-in-the-loop), prompt и context engineering, structured outputs, tool / function calling, роутинг моделей
- **Eval, guardrails и observability:** promptfoo с LLM-as-judge, тестовые стенды, PreToolUse guards, песочницы на пользователя, минимальные привилегии, трейсинг LangSmith, Sentry, Loki, Grafana
- **RAG и инференс:** retrieval (чанкинг, мультиязычные ONNX-эмбединги, векторные хранилища, SharePoint через Microsoft Graph), llama.cpp (квантизация, выгрузка MoE, спекулятивный декодинг), TensorRT, модели Whisper и TTS, ComfyUI
- **Провайдеры моделей и стек:** Anthropic, Ollama Cloud, OpenAI-совместимые API через LiteLLM, self-hosted open-weight Qwen / LFM / Gemma; Python (FastAPI, pytest), TypeScript, React, Electron, PostgreSQL, Supabase, SQLite, Docker, CI/CD на GitHub Actions, Dokploy, Tailscale; рабочее окружение: Arch Linux (Omarchy), Neovim, herdr
- **Образование и языки:** «Информационные системы и технологии», МИИГАиК, Москва (2013 — 2017); русский (родной), английский (свободный), сербский (базовый)